1. Visao geral do projeto

O Biomedical Data Digger e uma aplicacao web em Python/Gradio que recebe o identificador ou a URL de um artigo cientifico e devolve resumos e analises estruturadas geradas por modelo de linguagem.

A ideia central e reduzir o tempo de extracao de informacao relevante para profissionais da saude, estudantes e pesquisadores, com destaque para uso em pronto-socorro e UPA.

O que a aplicacao faz

- Busca direta por identificador: PMID, PMCID, DOI, arXiv ID, OpenAlex ID, Semantic Scholar ID ou URL completa.
- Busca por palavras-chave: consulta varias fontes publicas em paralelo e devolve artigos ordenados por um indicador de relevancia bibliografica.
- Resumos de tres estilos basicos: sumario conciso, resumo equilibrado e resumo introdutorio.
- Analises especializadas: resumo academico, resumo clinico, criticas metodologicas, estatisticas, PICO, alertas e contraindicacoes, checklist pre-conduta, medicamentos e protocolos, populacoes especiais, lacunas de pesquisa, comparacao com literatura, aplicabilidade brasileira, impacto na sociedade, vigilancia sanitaria, disponibilidade no SUS e outras.
- Filtros de personalizacao: publico-alvo, tom, idioma, nivel de detalhe e foco tematico.
- Caixa de usuario: cadastro, login e logout com persistencia local em SQLite ou PostgreSQL em producao.
- Memoria de sessao: cache dos ultimos 20 artigos e historico das ultimas 10 consultas.

Para quem ela serve

- O publico principal sao medicos, residentes, estudantes de medicina, enfermeiros, farmaceuticos e outros profissionais da saude.
- A interface oferece duas visoes orientadas por contexto: uma pagina geral de analise cientifica e uma pagina de medicina focada em pronto-socorro, farmacologia, seguranca do paciente e contexto brasileiro.

2. Como funciona a busca de artigos

- Quando o usuario cola um texto, o sistema classifica o input antes de consultar qualquer API.
- Essa etapa e feita por detect_input_type, que reconhece formatos como numero de PMID, PMCID, DOI, ID do arXiv, ID do OpenAlex, ID do Semantic Scholar, URL do Google Academico, URLs de editoras e links genericos.
- Exemplos de entradas aceitas sem formatacao especial: 33984217, PMC8234567,

10.1038/nature12373, 2301.00001, W2741809807, https://pubmed.ncbi.nlm.nih.gov/33984217/, https://doi.org/10.1038/nature12373, https://scholar.google.com/scholar?q=metformin+diabetes e qualquer URL de pagina de artigo.

- Depois de identificado o tipo, o sistema escolhe a busca certa: PMID e PMCID consultam Europe PMC, DOI tenta Semantic Scholar e depois Crossref, arXiv usa a API oficial, URLs de editoras extraiem meta tags da pagina e links do Google Academico sao resolvidos pela consulta ou pelo titulo.

Fontes consultadas em busca por palavras-chave

- Em busca por tema, o sistema consulta cinco fontes em paralelo: Europe PMC, OpenAlex, Semantic Scholar, Crossref e arXiv.
- Se uma fonte responder de forma inesperada, ela nao impede que as demais contribuam.
- Depois de coletadas, as respostas passam por normalizacao, deduplicacao e ordenacao.

Deduplicacao e normalizacao

- Cada resultado e convertido para um formato padronizado com titulo, revista, ano, DOI, PMID, URL e numero de citacoes unificado como cited_by.
- A deduplicacao usa DOI, PMID ou uma versao limpa e normalizada do titulo, porque cada API nomeia os campos de forma diferente.
- Esse tratamento evita que fontes nao medicas aparecam artificialmente mais baixas apenas por usarem nomes distintos para o mesmo conceito.

3. Como funciona o score de relevancia bibliografica

O score e um indicador de ordenacao para descoberta bibliografica.

Ele nao avalia qualidade metodologica, validade clinica ou risco de vies do estudo.

Ele representa o quanto o artigo e provavelmente relevante para uma busca exploratoria, combinando tres sinais objetivos e um sinal de cobertura da fonte.

Componentes e pesos

- Impacto por ano - 40% - citacoes divididas pela idade do artigo; o valor maximo e atingido em 20 citacoes por ano.
- Atualidade - 25% - pontuacao decresce linearmente ao longo de 15 anos. Artigos muito antigos perdem desse componente.
- Metadados - 20% - presença de titulo, revista, ano, DOI/PMID e URL nos dados retornados.
- Cobertura da fonte - 15% - peso tecnico da cobertura e identificacao oferecida pela fonte consultada.

Como o calculo e feito

- Idade do artigo = ano atual menos ano de publicacao, com valor minimo de 1 ano.

- Taxa de citacao = citacoes divididas pela idade.
- Impacto = taxa de citacao dividida por 20, limitado a 1.
- Atualidade = 1 menos idade dividida por 15, limitado a no minimo 0.
- Metadados = numero de campos presentes dentre titulo, revista, ano, DOI ou PMID e URL, dividido por 5.
- Fonte = peso atribuido a cada fonte, maior para PubMed/Europe PMC e menor para arXiv.
- Score final = soma ponderada, arredondada para dois decimais e limitada entre 0 e 0.99.

Classificacoes usadas na interface

- Alta relevancia bibliografica: score igual ou superior a 0.90.
- Boa relevancia bibliografica: score entre 0.75 e 0.89.
- Relevancia bibliografica moderada: score abaixo de 0.75.
- Essas faixas sao usadas apenas para ordenar e sinalizar resultados. Elas nao devem ser lidas como garantia de qualidade metodologica ou de valor clinico do artigo.

Exemplo de pontuacao

- Artigo recente, com 40 citacoes e ano de publicacao 2025: taxa de citacao alta, impacto maximo, atualidade maxima, metadados completos e fonte forte. O score resultante e alto.
- Artigo mais antigo, 2016, com 2 citacoes e mesmo conjunto de metadados: taxa de citacao baixa, atualidade reduzida e score consideravelmente menor, mesmo com metadados completos.
- O ponto importante e que dois artigos com os mesmos metadados podem ter scores bem diferentes apenas por causa da idade e das citacoes, porque esses sao os componentes que mais pesam no calculo.

4. Como sao gerados os resumos e analises

- Todas as analises sao feitas por um modelo de linguagem que recebe uma conversa com dois papéis: uma mensagem de sistema com as regras gerais e uma mensagem de usuario com o artigo e a tarefa.
- O ambiente de producao usa Groq API; o ambiente de desenvolvimento local usa Ollama.
- A escolha do backend e automatica: se GROQ_API_KEY estiver definida, o sistema usa Groq; caso contrario, ele tenta Ollama.

Prompt base e as regras que ele impoe

- Cada analise herda um prompt de sistema com instrucoes claras: respostas em portugues brasileiro, preservacao de termos tecnicos em ingles quando a traducao seria imprecisa, uso do abstract como unica fonte de fato por padrao e regra de informacao ausente que prescreve escrever 'Nao descrito no resumo fornecido'

quando algo nao pode ser determinado.

- O prompt tambem controla numeros e calculos: o modelo deve copiar valores como foram reportados e nao inventar, estimar ou aplicar limiares a menos que o artigo proprio forneaca o resultado ou o prompt autorize um calculo transparente baseado apenas nos valores presentes no texto.

Como uma analise especifica e montada

- Para cada tipo de analise existe uma funcao construtora que devolve uma lista com mensagem de sistema e mensagem de usuario.
- Essa mensagem de usuario contem o titulo, o abstract e instrucoes especificas da analise, como a estrutura obrigatoria, o que incluir e o que nunca inventar.

Análises disponíveis

- Resumo academico: pergunta de pesquisa, desenho, metodologia, achados com metricas quando disponiveis, analise critica de limitacoes e conclusao academica.
- Resumo clinico: pergunta clinica, populacao-alvo, intervencao, desfechos e implicacoes praticas.
- PICO: estruturação em paciente, intervencao, comparador, desfecho e extensao PICOT, com pergunta formatada e aplicabilidade.
- Estatisticas: metricas de efeito, intervalos de confianca, valores de p, NNT/NNH quando relatados, acuracidade diagnostica e interpretacao direta.
- Criticas metodologicas: desenho, amostra, vieses, validade interna e externa, qualidade estatistica e síntese critica.
- Alertas e contraindicacoes: situacoes de nao uso, populacoes de risco, efeitos adversos, interacoes e checklist rapido.
- Medicamentos e protocolos: nome, classe, posologia por perfil, compatibilidade, farmacocinetica, eficacia, seguranca, monitoramento e conduta em toxicidade.
- Aplicabilidade brasileira: separacao rigorosa entre dados do resumo e dados externos, com marcacoes de fonte e verificabilidade.

Personalizacao dos prompts

- Os filtros de publico, tom, idioma, nivel de detalhe e foco tematico nao substituem o prompt da analise.
- Eles sao anexados ao prompt de sistema como instrucoes adicionais.
- Se nenhum filtro for escolhido, o comportamento padrão de cada analise prevalece.
- Isso permite ajustar o estilo e o nivel de detalhe sem alterar o conteudo da analise.

Auditoria e comparacao

- A auditoria da resposta recebe o titulo, o abstract e a resposta ja gerada, e deve classificar cada afirmacao do resumo como suportada, parcialmente suportada, nao encontrada ou contraditoria, usando apenas o resumo como base.

- A comparacao de dois artigos recebe ambos os resumos e uma modalidade selecionada, como resultados, metodologia, populacoes, eficacia, seguranca ou estatistica, e deve manter as fontes separadas, reproduzir os valores exatamente e evitar declarar superioridade quando os dados nao permitirem.

5. Estrutura do codigo

- O projeto e organizado em modulos com responsabilidade separada.
- O arquivo principal orquestra a interface e as analises; os servicos ficam isolados para facilitar leitura e teste.

Arquivo e responsabilidade principal

- biomedical_data_digger.py - Interface Gradio, orquestracao das analises, paginas por contexto e fluxo do usuario.
- article_services.py - Detecao de identificadores, busca nas fontes, normalizacao, deduplicacao, cache e calculo de relevancia.
- llm_service.py - Selecao do backend Groq ou Ollama, configuracao de modelo e geracao de resposta sincrona ou em stream.
- prompt_builders.py - Prompt de sistema base, construtores de mensagem para cada analise e montador de personalizacao.
- account_store.py - Persistencia e autenticacao de contas. O banco usado depende da configuracao de producao ou desenvolvimento.
- tests/test_keyword_search.py - Testes da busca agregada, combinacao das fontes, filtros de area e calculo do score com campos normalizados.
- tests/test_link_resolution.py - Testes da detecao de input, resolucao de URL do Google Acadêmico, paginas de editora e fallbacks.
- contexto_brasil.py - Contexto curado do Brasil (fonte, codigo e data por item) e verificacao externa segura de fontes oficiais.
- tests/test_contexto_brasil.py - Testes do contexto curado, das regras de prompts BR e da verificacao externa.

6. Facilidades que apoiam a confiabilidade

Cache de sessao evita chamadas redundantes as fontes externas.

Historico de sessao ajuda o usuario a retomar consultas recentes.

Filtros de area permitem direcionar a busca por tema em vez de buscar em tudo.

Mensagens de erro claras em vez de falhas silenciosas quando a busca nao consegue o abstract.

Prompts com restricao absoluta de nao inventar informacao, especialmente nos contextos clinicos.

Camada de confiabilidade para o contexto brasileiro: contexto curado com fontes citadas, regras que exigem 'nao verificavel' quando falta evidencia e verificacao ao vivo das fontes oficiais.

7. Limitações importantes a comunicar

O score de relevancia nao e avaliacao de qualidade metodologica, validade clinica ou risco de vies.

As analises partem do abstract; texto completo existe em Europe PMC, mas ainda nao e opcao exposta na interface.

Streaming foi desligado na configuracao atual por causa de lentidao no plano free do Render.

O Render free pode hibernar apos periodo sem uso, o que aumenta o tempo da primeira resposta depois do retorno.

O auth e persistente apenas quando o banco de producao estiver configurado; a sessao da interface ainda e local.

8. Resumo expressivo do que o sistema entrega

Biomedical Data Digger e uma ferramenta de apoio a leitura de artigos cientificos que unifica identificacao automatica de input, busca multi-fonte, ordenacao por relevancia bibliografica, cache de sessao, prompts especializados em portugues e geracao de analises clinico-cientificas por modelo de linguagem.

Para o entrevistado, o ponto central e que o sistema nao avalia a qualidade do estudo: ele organiza, orienta e resume o que esta no artigo, deixando a interpretacao critica para o profissional.

9. Camada de confiabilidade do contexto brasileiro (atualizacao)

- As analises de Disponibilidade no SUS, Vigilancia Sanitaria e Aplicabilidade Brasileira agora tem uma camada propria de confiabilidade, para nunca apresentar contexto local como fato sem fonte.
- Contexto curado do Brasil - o modulo contexto_brasil.py mantem itens revisados (SUS, ANVISA, Vigilancia Sanitaria, medicamentos e populacoes especiais), cada um com fonte, codigo e data de atualizacao. O bloco relevante e injetado no prompt apenas quando o tema do artigo pedir.
- Regras obrigatorias nos tres prompts BR - o modelo so pode afirmar algo sobre SUS/regulacao se o resumo informar ou se o contexto curado trouxer com fonte indicada; caso contrario a resposta deve dizer 'Nao verificavel com as fontes acessiveis'. Todo item e marcado como [DO RESUMO], [CONTEXTO CURADO] ou [NAO VERIFICADO], com proibicao explicita de usar memoria externa ou suposicao.
- Verificacao externa ao vivo - a cada geracao dessas analises o sistema consulta as fontes oficiais catalogadas (so http/https, com timeout de 6 segundos, limite de 400KB e cache de 10 minutos) e anexa o status a resposta: fonte acessivel em verde, fonte fora do ar em vermelho. Falha de rede vira status explicito de nao-verificavel, nunca uma afirmacao silenciosa.
- Rigor verificado na pratica - a propria verificacao ja detectou uma URL oficial quebrada no catalogo (HTTP 404) e ela foi substituida por fonte oficial confirmada.

Sao 29 testes automatizados no total, sendo 8 novos para o contexto curado e a verificacao externa.